

PARTE 2 — IA LOCAL EN TU PROYECTO

Análisis Estratégico, Operativo y Técnico de la Adopción de Modelos SLM y VLM On-Premise en el Sistema RefuGuía

CONTEXTO OPERATIVO Y MARCO CONCEPTUAL:

Un LLM local (Ollama + LLaMA, Mistral, Phi-3) o un SLM (Small Language Model: Phi-3 Mini, Gemma 2B, Qwen 2.5 1.5B, Moondream 1.4B) corre completamente en tu computadora o servidor de campaña. No envía datos a la nube comercial. No tiene costo por token. Funciona sin internet.

En organizaciones de respuesta humanitaria, protección civil y refugios de emergencia, un SLM local representa la frontera entre una solución que puede operar en escenarios de corte total de telecomunicaciones respetando la privacidad de las familias damnificadas y una herramienta inutilizable por falta de conectividad o inviable por riesgos de filtración de datos sensibles.

1. ¿Qué papel jugaría un LLM/SLM local en tu proyecto?

En RefuGuía, los modelos de IA local no son un mero componente secundario de apoyo, sino el núcleo operativo, soberano y vital de toda la arquitectura. El sistema implementa una arquitectura dual de agentes locales ejecutados sobre Ollama (host local): (1) Qwen 2.5 (1.5B) como Agente Principal Lingüístico, encargado de la sanitización contra Prompt Injection, extracción estructurada de entidades clínicas/físicas en formato JSON estricto y generación de embeddings semánticos, y (2) Moondream:latest (1.4B VLM) como Agente Especializado de Peritaje Visual Multimodal, responsable de analizar las fotografías de rescates y reportes píxel a píxel para identificar manto, orejas, hocico y cotejar coincidencias anatómicas reales.

Esta configuración local reemplaza al 100% la dependencia de APIs comerciales en la nube (como OpenAI GPT-4o, Anthropic Claude o Google Gemini), las cuales quedarían totalmente inoperativas ante el corte de fibra óptica, colapso de torres celulares o apagón general que acompaña a un sismo de gran magnitud. Además, permite realizar algo que antes era inviable técnica y económicamente: procesar de manera continua, ilimitada y sin costo marginal miles de relatos ciudadanos y peritajes de imágenes pesadas en alta resolución directamente en laptops de campaña, manteniendo latencias ultrabajas (160–280 ms por inferencia) sin saturar el escaso ancho de banda disponible.

2. ¿Qué le aportaría al usuario de la aplicación?

Al usuario de la aplicación (familias damnificadas, rescatistas en campo, coordinadores de refugio y adoptantes), la IA local les aporta tres beneficios transformadores: Disponibilidad Ininterrumpida (Resiliencia Offline), Velocidad de Respuesta y Privacidad Absoluta (Zero Data Leakage). Para una persona damnificada que busca desesperadamente a su mascota en medio de la catástrofe, el sistema funciona de inmediato sin requerir conexión a internet móvil ni saldo de datos; puede dictar por voz relatos en lenguaje natural con modismos venezolanos ('Perdí a Toby en Catia, es negro con mancha blanca') y subir fotos familiares sin temor a que sus imágenes o ubicaciones sean enviadas a servidores extranjeros o expuestas públicamente.

Asimismo, la aplicación se vuelve sumamente económica y accesible: elimina cualquier cobro o cuota por uso de tokens, permitiendo a los rescatistas ingresar cientos de animales en minutos mediante plantillas de un solo toque y al personal veterinario generar fichas clínicas y collares QR físicos de forma instantánea. Esto cambia

radicalmente lo que el usuario puede pedirle al sistema: ya no está restringido a formularios rígidos de casillas, sino que puede comunicarse libremente mediante lenguaje conversacional y fotografía, recibiendo dictámenes periciales claros, transparentes y libres de tecnicismos intimidantes.

3. ¿Qué te aportaría a vos como profesional?

Como profesional de ingeniería de software e inteligencia artificial aplicada, dominar y desplegar modelos SLM/VLM locales representa un salto cualitativo hacia la soberanía tecnológica y la observabilidad profunda. Al ejecutar el modelo en infraestructura propia (on-premise), obtengo acceso directo y transparente a toda la telemetría interna del sistema: velocidad de generación de tokens (tokens/segundo), distribución de memoria RAM y VRAM, vectores de embedding en ChromaDB, distancias exactas de Coseno y logs de auditoría sin intermediarios. Esto me permite analizar patrones de extravío por zonas geográficas, correlaciones fenotípicas y tendencias en la administración de fármacos críticos que bajo una API de terceros sería imposible o legalmente inviable debido a restricciones de confidencialidad médica y protección de datos.

En la dinámica de trabajo diaria, disponer de esta herramienta 100% offline transforma por completo el flujo de desarrollo y despliegue: elimina la dependencia de llaves de API que caducan, presupuestos mensuales imprevistos por sobreconsumo o caídas de servicio de proveedores externos. Permite construir soluciones de 'misión crítica' empaquetadas en contenedores Docker portables que pueden ser encendidas en cualquier laptop en una carpa de campaña, posicionándome como un arquitecto de soluciones de IA robustas, autosuficientes, éticamente responsables y listas para el mundo real.

4. ¿Qué limitaciones concretas tiene versus una API en la nube?

A pesar de sus inmensas ventajas en privacidad, costo cero y funcionamiento offline, la adopción de modelos locales presenta tres limitaciones concretas que deben ser gestionadas mediante rigurosa ingeniería de software:

1. Capacidad del Hardware Disponible: Los modelos locales dependen estrictamente de los recursos de la máquina anfitriona (CPU, RAM y VRAM). En RefuGuía se requirió seleccionar modelos altamente optimizados y cuantizados (Qwen 2.5 1.5B y Moondream 1.4B en cuantización Q4_K_M) para no sobrepasar los 3 GB de RAM combinados, impidiendo cargar modelos de gran escala (>70B) que requerirían GPUs de grado servidor inviables en campamentos de emergencia.
2. Calidad y Capacidad de Razonamiento Abstracto: Un modelo pequeño (SLM) posee un conocimiento general y capacidad de razonamiento abstracto inferior a gigantes comerciales como GPT-4o o Claude 3.5 Sonnet. Para mitigar esto en RefuGuía, fue necesario diseñar System Prompts altamente delimitados ('Role-Prompting'), técnicas de sanitización estricta y esquemas JSON fuertemente tipados para evitar alucinaciones o desvíos de formato.
3. Mantenimiento y Actualización Descentralizada: En las APIs en la nube, las mejoras y parches del modelo ocurren de forma transparente en los servidores del proveedor. En un despliegue On-Premise, el ciclo de vida del modelo (actualización de pesos .gguf, recalibración de prompts y afinamiento de hiperparámetros de Ollama) debe ser gestionado manualmente por el equipo técnico mediante scripts de orquestación y versionamiento local.

Tabla Comparativa: IA Local On-Premise (RefuGuía) vs API Comercial en la Nube

Dimensión Operativa / Técnica	IA Local On-Premise (Qwen 2.5 + Moondream)	API Comercial en la Nube (GPT-4o / Claude)
Conectividad e Internet	100% Funcional sin internet (Offline / Campaña).	Inoperable si colapsa la red de telecomunicaciones.

Costo Operativo	\$0.00 USD (Cero costo por token / peticiones infinitas).	Facturación recurrente por token y ancho de banda.
Privacidad y Soberanía	Zero Data Leakage (Datos no salen de la laptop/servidor).	Datos viajan y se procesan en servidores externos.
Latencia de Inferencia	160–280 ms (Procesamiento directo en RAM/VRAM local).	500–2500 ms (Dependiente del ping y congestión de red).
Demanda de Hardware	Requiere 3–4 GB de RAM local (Optimizado Q4_K_M).	Cero consumo de hardware local (Cómputo en la nube).